

Les méthodes MCMC pour estimer des espérances et le débiaisement des estimateurs MCMC

Anatole Coulais

Université de Montréal

30/11/2023

Unbiased Markov chain Monte Carlo methods with couplings

Pierre E. Jacob,

Harvard University, Cambridge, USA

John O’Leary

Harvard University, Cambridge, and Acadian Asset Management, Boston, USA

and Yves F. Atchadé

Boston University, USA

- 1 Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances.
 - L'idée des méthodes MCMC
 - L'algorithme de Metropolis-Hastings : comment simuler une chaîne de Markov de loi stationnaire π
 - Un exemple de l'algorithme de Metropolis-Hastings
- 2 Méthode de débiaisement des MCMC
 - Définition du processus $((X_t, Y_t))_{t \geq 0}$
 - Définition de l'estimateur MCMC sans biais
- 3 Simulation de l'estimateur MCMC sans biais
 - Première tentative de simulation avec un couplage naïf du processus
 - Deuxième tentative avec la simulation d'un couplage maximal
 - Exemple $H_{k:m}(X, Y)$ pour approcher μ

/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

1) L'idée des méthodes MCMC

Soient $\mathcal{X} \subset \mathbb{R}^d$, $\pi : \mathcal{B}(\mathcal{X}) \mapsto [0 : 1]$ une mesure de probabilité, $h : \mathcal{X} \mapsto \mathbb{R}$ mesurable telle que $\mathbb{E}_\pi(|h(X)|^p) < \infty$ avec $p > 2$ et $(X_t)_{t \geq 0}$ une chaîne de Markov telle que $\lim_{t \rightarrow \infty} \mathbb{E}(h(X_t)) = \mathbb{E}_\pi(h(X))$

On cherche à estimer $\mu := \mathbb{E}_\pi(h(X)) = \int_{\mathcal{X}} h(x)\pi(x)dx$.

Idee des méthodes MCMC : il existe une loi des grands nombres pour les chaînes de Markov. On peut avoir :

$$\frac{1}{T} \sum_{t=0}^{T-1} h(X_t) \xrightarrow[T \rightarrow +\infty]{p.s.} \mathbb{E}_\pi(h(X))$$

On a donc une autre méthode que Monte Carlo pour estimer μ . Avec les méthodes MCMC, il n'est pas nécessaire de simuler des copies i.i.d de π .

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

1) L'idée des méthodes MCMC

- Probabilité stationnaire : $(X_t)_{t \geq 0}$ admet π comme probabilité stationnaire (ou invariante) :

$$\text{Si } \exists N \geq 0 \text{ tel que } X_N \sim \pi \implies \forall n \geq N, X_n \sim \pi$$

On a l'intuition que sous certaines conditions supplémentaires, la chaîne $(X_t)_{t \geq 0}$ qui admet π comme loi invariante va avoir : $X_t \xrightarrow[t \rightarrow +\infty]{\mathcal{L}} \pi$

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

1) L'idée des méthodes MCMC

Théorème Ergodique : La loi des grands nombres pour les chaînes de Markov :

- Si $(X_t)_{t \geq 0}$ est une chaîne de Markov, de loi stationnaire π , irréductible, on a :

$$\frac{1}{T} \sum_{t=0}^{T-1} h(X_t) \xrightarrow[T \rightarrow +\infty]{p.s.} \mathbb{E}_{\pi}(h(X)) = \mu$$

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

2) L'algorithme de Metropolis-Hastings : comment simuler une chaîne de Markov de loi stationnaire π

Algorithme de Metropolis-Hastings :

- Noyau de proposition : $Q(X_t, \cdot)$ une loi de probabilité facile à simuler qui dépend de $X_t \in \mathcal{X}$. On note $q(X_t, \cdot)$ sa densité.

(Souvent, quand $\mathcal{X} = \mathbb{R}$, on utilise $Q(x, \cdot) = \mathcal{N}(x, \sigma^2)$ ou $Q(x, \cdot) = U([x - 1, x + 1])$ où $x \in \mathbb{R}$.)

- Fonction d'acceptation : $\alpha(x, y) = \min \left[1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} \right]$

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

2) L'algorithme de Metropolis-Hastings : comment simuler une chaîne de Markov de loi stationnaire π

Algorithme de Metropolis-Hastings :

$X_0 \sim \pi_0$ (loi de X_0)
 $\forall t \in \mathbb{N}, U \sim U([0, 1])$ et $X^* \sim Q(X_t, \cdot)$
- if $U \leq \alpha(X_t, X^*)$: $X_{t+1} = X^*$ (proposition acceptée)
 else : $X_{t+1} = X_t$ (proposition refusée)

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

2) L'algorithme de Metropolis-Hastings : comment simuler une chaîne de Markov de loi stationnaire π

Grâce à α , $(X_t)_{t \geq 0}$ est π -stationnaire (et est irréductible). $(X_t)_{t \geq 0}$ vérifie les hypothèses du théorème Ergodique et avec d'autres hypothèses vérifiées par l'algorithme de Metropolis-Hastings, on a :

$$\lim_{T \rightarrow \infty} \mathbb{E} \left(\frac{1}{T} \sum_{t=0}^{T-1} h(X_t) \right) = \mathbb{E}_{\pi}(h(X))$$

L'estimateur est biaisé mais asymptotiquement sans biais.

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

2) L'algorithme de Metropolis-Hastings : comment simuler une chaîne de Markov de loi stationnaire π

Rodage : Comme $X_t \xrightarrow[t \rightarrow +\infty]{\mathcal{L}} \pi$ mais que l'on n'a pas $\mathcal{L}(X_t) = \pi \forall t \in \mathbb{N}$ les premières réalisations de X_t peuvent ne pas ressembler à π . Il est courant d'enlever les $k \in \mathbb{N}$ premiers X_t dans l'estimateur :

$$\frac{1}{T - k + 1} \sum_{t=k}^T h(X_t)$$

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

3) Un exemple de l'algorithme de Metropolis-Hastings

Exemple, l'algorithme de Metropolis-Hastings :

$$\forall x \in \mathbb{R}, \pi(x) := \frac{e^{-x}}{C} \mathbb{I}_{[0,1]}(x) \text{ où } C := \int_0^1 e^{-x} dx (= 1 - e^{-1})$$

$$Q(x, \cdot) := U\left([x - \frac{3}{4} : x + \frac{3}{4}]\right) \text{ et } h(x) := Cx.$$

On souhaite estimer :

$$\mathbb{E}_{\pi}(h(X)) = \int_0^1 x e^{-x} dx (= 1 - 2e^{-1})$$

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

3) Un exemple de l'algorithme de Metropolis-Hastings

Avec l'algorithme de Metropolis on obtient :

$$\frac{1}{T - k + 1} \sum_{t=k}^T h(x_t) = 0.26389 \approx 1 - 2e^{-1} = \mathbb{E}_\pi(h(X)) \approx 0.26424$$

Où $(x_t)_{t \in \llbracket k, T \rrbracket}$ est une réalisation de $(X_t)_{t \in \llbracket k, T \rrbracket}$ avec $k = 1000$ et $T = 10^6$.

I/ Les méthodes MCMC et l'algorithme de Métropolis-Hastings pour estimer des espérances I

3) Un exemple de l'algorithme de Metropolis-Hastings

$\frac{1}{T-k+1} \sum_{t=k}^T h(X_t)$ est biaisé mais asymptotiquement sans biais :


Abscisse :

$$T \in \llbracket 100, 10\,000 \rrbracket$$

Ordonnée :

$$\frac{1}{R} \sum_{r=1}^R \hat{\mu}_{k,T}^{(r)} - \mathbb{E}_{\pi}(h(X)) \approx \mathbb{E} \left[\frac{1}{T-k+1} \sum_{t=k}^T h(X_t) - \mathbb{E}_{\pi}(h(X)) \right]$$

avec $R = 100$ et $k = 100$



II/ Méthode de débiaisement des MCMC I

1) Définition du processus $((X_t, Y_t))_{t \geq 0}$

- $((X_t, Y_t))_{t \geq 0}$ avec $(Y_t)_{t \geq 0}$ étant une copie de $(X_t)_{t \geq 0}$, qui suit l'algorithme de Metropolis-Hastings de loi cible π et de noyau de proposition $Q(., .)$. $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ sont corrélées Dans $((X_t, Y_t))_{t \geq 0}$.

- $((X_{t+1}, Y_t))_{t \geq 0}$ est une chaîne de Markov telle que :

après que $\tau := \inf\{t \geq 1 : X_t = Y_{t-1}\}$ soit réalisé les chaînes restent égales : $\forall t \geq \tau, X_t = Y_{t-1}$.

II/ Méthode de débiaisement des MCMC I

1) Définition du processus $((X_t, Y_t))_{t \geq 0}$

On peut définir $((X_t, Y_t))_{t \geq 0}$ pour d'autres algorithmes MCMC que Metropolis-Hastings. Mais dans ce cas, $((X_t, Y_t))_{t \geq 0}$ doit satisfaire des propriétés supplémentaires qui étaient induites par le fait que $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ suivent l'algorithme de Metropolis-Hastings.

II/ Méthode de débiaisement des MCMC I

2) Définition de l'estimateur MCMC sans biais

On souhaite trouver un estimateur H tel que : $\mathbb{E}(H) = \mathbb{E}_\pi(h(X))$. Soit $l \in \mathbb{N}$:

$$\mathbb{E}_\pi(h(X)) = \lim_{t \rightarrow \infty} \mathbb{E}(h(X_t)) \quad (\text{hypothèse sur } (X_t)_{t \geq 0})$$

$$= \mathbb{E}(h(X_l)) + \left[\lim_{t \rightarrow \infty} \mathbb{E}(h(X_t)) - \mathbb{E}(h(X_l)) \right]$$

$$= \mathbb{E}(h(X_l)) + \sum_{t=l+1}^{\infty} [\mathbb{E}(h(X_t)) - \mathbb{E}(h(X_{t-1}))] \quad (\text{télescopage})$$

$$= \mathbb{E}(h(X_l)) + \sum_{t=l+1}^{\infty} \mathbb{E} [h(X_t) - h(Y_{t-1})] \quad (\mathcal{L}(X_{t-1}) = \mathcal{L}(Y_{t-1}))$$

$$= \mathbb{E} \left[h(X_l) + \sum_{t=l+1}^{\infty} (h(X_t) - h(Y_{t-1})) \right] \quad (\text{Inversion série/espérance})$$

II/ Méthode de débiaisement des MCMC I

2) Définition de l'estimateur MCMC sans biais

Enfin puisque, $\forall t \geq \tau$, $X_t = Y_{t-1}$, on a :

$$\mathbb{E}_\pi(h(X)) = \mathbb{E} \left[h(X_l) + \sum_{t=l+1}^{\tau-1} (h(X_t) - h(Y_{t-1})) \right] .$$

Donc $H_l(X, Y) := h(X_l) + \sum_{t=l+1}^{\tau-1} (h(X_t) - h(Y_{t-1}))$ est un estimateur sans biais de μ .

II/ Méthode de débiaisement des MCMC I

2) Définition de l'estimateur MCMC sans biais

Soit $m \in \mathbb{N}^*$:

Pour calculer une réalisation de $H_m(X, Y)$ il faut simuler $((X_t, Y_{t-1}))_{t \geq 1}$ jusqu'à $\max(\tau, m)$.

Mais comme $\max(\tau, l) \leq \max(\tau, m)$ pour tout $l \in \llbracket 1, m \rrbracket$, avec la même réalisation de la chaîne, on peut calculer $H_l(X, Y)$ pour tout $l \in \llbracket 1, m \rrbracket$.

Soient $k \in \mathbb{N}$ et $m \geq k$, on peut donc considérer l'estimateur sans biais :

$$H_{k:m}(X, Y) := \frac{1}{m - k + 1} \sum_{l=k}^m H_l(X, Y).$$

II/ Méthode de débiaisement des MCMC I

2) Définition de l'estimateur MCMC sans biais

Après reformulation, l'estimateur peut également s'écrire :

$$H_{k:m}(X, Y) = \frac{1}{m - k + 1} \sum_{l=k}^m h(X_l) + \sum_{l=k+1}^{\tau-1} \min(1, \frac{l - k}{m - k + 1}) [h(X_l) - h(Y_{l-1})]$$

III/simulation de $H_{k:m}(X, Y)$ I

1) Première tentative de simulation avec un couplage naïf du processus

L'objectif est maintenant de simuler $\max(\tau, m)$ itérations de $((X_t, Y_{t-1}))_{t \geq 1}$ afin de calculer une réalisation de $H_{k:m}(X, Y)$.

On veut que :

- 1) les deux chaînes $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ suivent marginalement l'algorithme de Metropolis-Hastings.
- 2) $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ soient couplées de sorte qu'après que τ soit réalisé, elles restent égales : $\forall t \geq \tau, X_t = Y_{t-1}$.

Il suffit de simuler les deux chaînes indépendamment en suivant l'algorithme de Metropolis-Hastings jusqu'à ce que τ soit réalisé. Ensuite, il faut les coupler de manière à ce qu'elles continuent de suivre marginalement l'algorithme de Metropolis-Hastings tout en restant égales l'une à l'autre.

III/simulation de $H_{k:m}(X, Y)$ I

1) Première tentative de simulation avec un couplage naïf du processus

Première tentative de simulation de $((X_t, Y_{t-1}))_{t \geq 1}$:

- $X_0 \sim \pi_0, Y_0 \sim \pi_0$
- $U \sim U([0, 1]), X^* \sim Q(X_0, \cdot)$
if $U \leq \alpha(X_0, X^*) : X_1 = X^*$
else : $X_1 = X_0$
- $\forall t \in \llbracket 1, \tau - 1 \rrbracket$ (i.e $X_t \neq Y_{t-1}$) :
 $U, V \sim U([0, 1]), X^* \sim Q(X_t, \cdot)$ et $Y^* \sim Q(Y_{t-1}, \cdot)$
if $U \leq \alpha(X_t, X^*) : X_{t+1} = X^*$
else : $X_{t+1} = X_t$
if $V \leq \alpha(Y_{t-1}, Y^*) : Y_t = Y^*$
else : $Y_t = Y_{t-1}$

III/simulation de $H_{k:m}(X, Y)$. I

1) Première tentative de simulation avec un couplage naïf du processus

Première tentative de simulation de $((X_t, Y_{t-1}))_{t \geq 1}$:

On utilise U pour les deux chaînes. Puisque $X_t = Y_{t-1}$,
 $Q(X_t, \cdot) = Q(Y_{t-1}, \cdot)$ et X^* peut également servir de proposition pour Y_t .

- $\forall t \in \llbracket \tau, m-1 \rrbracket$ (donc $X_t = Y_{t-1}$) :

$U \sim U([0, 1])$, $X^* \sim Q(X_t, \cdot) = Q(Y_{t-1}, \cdot)$

- if $U \leq \alpha(X_t, X^*) \iff U \leq \alpha(Y_{t-1}, X^*)$: $X_{t+1} = X^*$ et $Y_t = X^*$ (et on a $X_{t+1} = Y_t$)

else : $X_{t+1} = X_t$ et $Y_t = Y_{t-1}$ (et on a $X_{t+1} = Y_t$)

Il reste ensuite à calculer $H_{k:m}(X, Y)$ avec les (X_t, Y_{t-1}) que l'on a simulés.

III/simulation de $H_{k:m}(X, Y)$ I

1) Première tentative de simulation avec un couplage naïf du processus

Toutefois, même si l'algorithme permet en théorie de simuler $H_{k:m}(X, Y)$. En pratique, comme $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ sont indépendantes avant que τ soit réalisé, si X_t et Y_{t-1} sont continues, $\mathbb{P}(\tau = t) = 0 \ \forall t \geq 1$.

L'algorithme a dans certains cas un temps infini de calcul.

III/ Simulation de $H_{k:m}(X, Y)$. I

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

Objectifs :

- 1) Maximiser la probabilité du temps d'arrêt τ à chaque étape $t \in \mathbb{N}^*$ tout en gardant les lois marginales de la chaînes inchangées.
- 2) Trouver une façon de simuler le processus $((X_t, Y_t))_{t \geq 0}$ avec la probabilité du temps d'arrêt τ maximisée.

III/ Simulation de $H_{k:m}(X, Y)$. I

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

Soit $t \geq 1$, on veut trouver un couplage maximal de $(X_{t+1}, Y_t)|X_t, Y_{t-1}$ i.e maximiser $\mathbb{P}(X_{t+1} = Y_t|X_t, Y_{t-1})$ en fonction de $\mathcal{L}((X_{t+1}, Y_t)|X_t, Y_{t-1})$ sous la condition que marginalement, $\mathcal{L}(X_t|X_{t-1}) = \nu_1$ et $\mathcal{L}(Y_{t-1}|Y_{t-2}) = \nu_2$ sont inchangées.

i.e, trouver la loi $\mathcal{L}((X_{t+1}, Y_t)|X_t, Y_{t-1})$ qui vérifie :

$$\begin{aligned} & \mathbb{P}(X_{t+1} = Y_t|X_t, Y_{t-1}) \\ &= \max\{\mathbb{P}(X_{t+1} = Y_t|X_t, Y_{t-1}) : X_{t+1}|X_t \sim \nu_1, Y_t|Y_{t-1} \sim \nu_2\} \end{aligned}$$

III/ Simulation de $H_{k:m}(X, Y)$. I

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

L'objectif est maintenant de simuler :

$(X_{t+1}, Y_t) \sim \text{CouplageMaximal}(\mathcal{L}(X_{t+1}), \mathcal{L}(Y_t))$ sachant X_t et Y_{t-1} .

Il suffit de simuler la même variable $U \sim U([0 : 1])$ pour les deux chaînes et
 $(X^*, Y^*) \sim \text{CouplageMaximal}(Q(X_t, .), Q(Y_{t-1}, .))$

Simuler un couplage maximal de $Q(X_t, .)$ et $Q(Y_{t-1}, .)$:

1) $X^* \sim Q(X_t, .), U \sim U([0 : 1])$

if $Uq(X_t, X^*) \leq q(Y_{t-1}, X^*) : Y^* = X^*$

2) else : $Y^* \sim Q(Y_{t-1}, .), U \sim U([0 : 1])$

while $Uq(Y_{t-1}, Y^*) \leq q(X_t, Y^*)$

$Y^* \sim Q(Y_{t-1}, .), U \sim U([0 : 1])$

III/ Simulation de $H_{k:m}(X, Y)$.

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

Résultats sur ce couplage :

- En moyenne, le coût de calcul du couplage maximal des noyaux de proposition avec cet algorithme est faible.
- Mais la variance de ce coût de calcul tend vers l'infini lorsque $\|Q(X_t, \cdot) - Q(Y_{t-1}, \cdot)\|_{TV} \rightarrow 0$
- Pour remédier à ce problème, il existe une autre technique pour simuler des variables aléatoires qui suivent le couplage maximal. Cependant, cette méthode suppose que les lois vérifient certaines propriétés.

III/ Simulation de $H_{k:m}(X, Y)$.

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

Simulation de $H_{k:m}(X, Y)$:

1) - $X_0 \sim \pi_0, Y_0 \sim \pi_0$

- $U \sim U([0, 1]), X^* \sim Q(X_0, \cdot)$

if $U \leq \alpha(X_0, X^*) : X_1 = X^*$

else : $X_1 = X_0$

2) $\forall t \in \llbracket 1, \tau - 1 \rrbracket$ (i.e $X_t \neq Y_{t-1}$) :

$U \sim U([0, 1]), (X^*, Y^*) \sim \text{CouplageMaximal}(Q(X_t, \cdot), Q(Y_{t-1}, \cdot))$

- if $U \leq \alpha(X_t, X^*) : X_{t+1} = X^*$

else : $X_{t+1} = X_t$

- if $U \leq \alpha(Y_{t-1}, Y^*) : Y_t = Y^*$

else : $Y_t = Y_{t-1}$

III/ Simulation de $H_{k:m}(X, Y)$.

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

Simulation de $H_{k:m}(X, Y)$:

3) $\forall t \in \llbracket \tau, m \rrbracket$ (donc $X_t = Y_{t-1}$) :

$U \sim U([0, 1])$, $X^* \sim Q(X_t, \cdot) = Q(Y_{t-1}, \cdot)$

- if $U \leq \alpha(X_t, X^*) \iff U \leq \alpha(Y_{t-1}, X^*)$: $X_{t+1} = X^*$ et $Y_t = X^*$

else : $X_{t+1} = X_t$ et $Y_t = Y_{t-1}$

4) $\forall l \in \llbracket k, m \rrbracket$, On définit la variable

$$H_l(X, Y) = h(X_k) + \sum_{t=l+1}^{\tau-1} (h(X_t) - h(Y_{t-1}))$$

$$\text{Et enfin on définit } H_{k:m}(X, Y) = \frac{1}{m - k + 1} \sum_{l=k}^m H_l(X, Y)$$

III/ Simulation de $H_{k:m}(X, Y)$.

2) Deuxième tentative de simulation à l'aide d'un couplage maximal

On a bien :

- $(X_t)_{t \geq 0}$ et $(Y_t)_{t \geq 0}$ qui suivent marginalement l'algorithme de Metropolis-Hastings de loi cible π avec le même noyau de proposition $Q(., .)$
- $\forall t \geq \tau, X_t = Y_{t-1}$ et puisque l'on utilise la même loi uniforme $U \sim U([0, 1])$ et que les noyaux de proposition sont couplés, cela maximise la probabilité du temps d'arrêt.

III/ Simulation de $H_{k:m}(X, Y)$.

3) Exemple simulation de $H_{k:m}(X, Y)$

On utilise le même exemple :

$$\forall x \in \mathbb{R}, \pi(x) := \frac{e^{-x}}{C} \mathbb{I}_{[0,1]}(x) \text{ où } C := \int_0^1 e^{-x} dx (= 1 - e^{-1})$$

$$Q(x, \cdot) := U([x - \frac{3}{4} : x + \frac{3}{4}]) \text{ et } h(x) := Cx.$$

On souhaite estimer :

$$\mathbb{E}_{\pi}(h(X)) = \int_0^1 xe^{-x} dx (= 1 - 2e^{-1})$$

III/ Simulation de $H_{k:m}(X, Y)$.

3) Exemple simulation de $H_{k:m}(X, Y)$

$H_{k:m}(X, Y)$ est bien un estimateur sans biais de μ :


Abscisse :

$$R \in \llbracket 1, 100\,000 \rrbracket$$

Ordonnée :

$$\frac{1}{R} \sum_{r=1}^R H_{5:10}^{(r)}(X, Y) - \mathbb{E}_{\pi}(h(X)) \approx$$

$$\mathbb{E}[H_{5:10}(X, Y) - \mathbb{E}_{\pi}(h(X))]$$



FIN DE LA PRESENTATION